

Design Robô	
Nome do Robô	Quantowsky
Explicação Nome	O nome é inspirado no “Piotroski Score” e no “Risk Parity” e revela, também homenagem ao renomados acadêmicos Joseph Piotroski e Markowitz, cujas contribuições revolucionaram o campo. Os documentos em baixo do robô representam os documentos DRE's usados como fontes para cálculo do F-score, a balança representa o Risk parity.
Hipótese da estratégia	Estratégia baseada na adaptação do modelo de Piotroski Score e de Risk Parity, de Joseph Piotroski e Markowitz, respectivamente. A união do Piotroski Score (uma abordagem fundamentalista e de seleção de ativos) com a Risk Parity (uma abordagem quantitativa e de alocação de risco) cria uma estratégia de investimento robusta, capaz de selecionar empresas de qualidade e, ao mesmo tempo, otimizar a distribuição do risco no portfólio.
Tipo de Estratégia	Portfólio
Classe de Ativos	Ações
Universo	IBOV
Holding Period	1 ano
Qual Plataforma Testou a estratégia	Python
Benchmark Estratégia:	IBOV

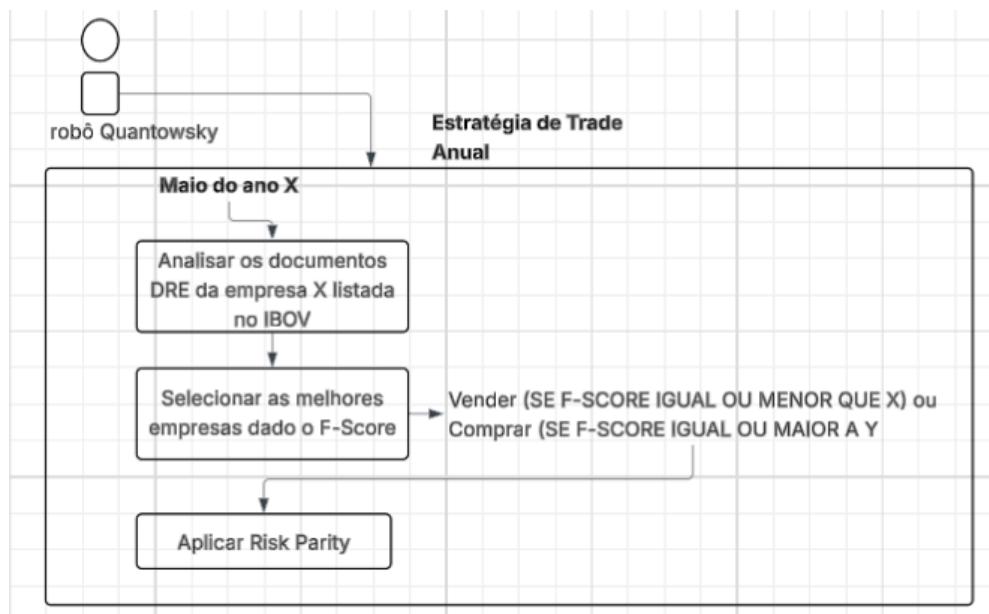
1. Factsheet

A tese "Quantowski" é uma estratégia quantamental que explora a ineficiência de mercado onde empresas financeiramente robustas (Qualidade), quando compradas a preços razoáveis (Valor), tendem a superar o mercado no longo prazo. Nossa hipótese é que um filtro de qualidade, como o Piotroski F-Score, pode efetivamente separar "vencedores" de "perdedores" dentro de um universo de ações. No entanto, a seleção fundamentalista por si só não gerencia o risco do portfólio.

Para resolver isso, unimos o F-Score a um otimizador quantitativo, o Risk Parity (ERC). Em vez de alocar capital igualmente ($1/N$), o Risk Parity aloca pesos de forma que cada ativo selecionado contribua com a mesma quantidade de risco para a carteira. O objetivo é construir um portfólio que não apenas capture o prêmio do fator "Qualidade", mas que também seja estruturalmente mais resiliente, visando gerar retornos superiores ajustados ao risco.

O universo de ativos refere-se à composição do Ibovespa. Partimos de todas as empresas não-financeiras listadas no Ibovespa com dados públicos disponíveis no Portal de Dados Abertos da CVM. Este universo é então filtrado dinamicamente em cada rebalanceamento anual por Liquidez (volume médio diário > R\$ 1 milhão).

1.1 Fluxograma básico da estratégia:



2. Introdução

Em 2000, Joseph Piotroski criou um modelo, chamado de Piotroski Score, poderoso para avaliar a solidez financeira de uma empresa e seu potencial como investimento de valor. Nomeado em homenagem a Joseph Piotroski, esse score varia de 0 a 9, com pontuações mais altas sugerindo uma saúde financeira mais sólida. Ele utiliza nove critérios específicos extraídos de demonstrações financeiras para distinguir entre oportunidades de investimento fortes e fracas, oferecendo insights cruciais para os investidores.

A alocação baseada em Risk Parity (paridade de risco) é um método de alocação de carteira que bebe da água da Teoria Moderna de Portfólio (MPT) iniciada por Markowitz, utilizando o risco para determinar alocações de uma carteira.

Essa evolução de modelos quantitativos reflete a busca contínua por modelos mais sofisticados e abrangentes que possam explicar e capturar os retornos das ações de forma mais precisa. Os modelos descritos acima tem sido amplamente utilizado na prática de investimentos e continua a ser objeto de estudo e pesquisa na área financeira.

2.1 Ideia de Investimento

A ideia de investimento proposta consiste em desenvolver um modelo que une as premissas do Piotroski Score com o modelo de Risk Parity com o objetivo de otimizar o retorno para o mercado brasileiro, tendo um alfa baixo e estatisticamente não significante. O nosso modelo parte de uma adaptação dos modelos citados anteriormente, levando em conta as peculiaridades do mercado nacional para as escolhas dos prêmios de riscos.

3. Modelagem

A primeira fase da nossa estratégia é um processo de filtragem robusto e sequencial, desenhado para selecionar um portfólio que combine alta qualidade fundamental

3.1 Definição do Universo Investível

Partindo do Ibovespa, excluímos todas as empresas do setor financeiro. O modelo F-Score de Piotroski não é projetado para avaliar a estrutura contábil específica de bancos e seguradoras.

Em seguida, aplicamos um critério de liquidez, eliminando ações com volume médio diário de negociação inferior a R\$ 1 milhão (calculado sobre os 12 meses anteriores à data de rebalanceamento). Esta etapa é crucial para garantir que a estratégia seja replicável e que os custos de transação (como slippage) sejam minimizados. O conjunto de ações remanescente forma o nosso "Universo Investível".

Abaixo estão os 9 critérios que usamos para calcular o score (de 0 a 9) para as empresas que passaram no filtro de valor, onde para cada item satisfeito, era somado 1 ponto à empresa

3.2 Pontuação F-Score escolhida para o modelo:

Rentabilidade

1. Lucro Líquido (positivo)
2. Fluxo de Caixa Oper. (FCO) (positivo)
3. ROA Crescente (ROA atual > ROA anterior)
4. Qualidade do Lucro (FCO > Lucro Líquido)

Alavancagem/Liquidez

5. Alavancagem Menor (Proxy: Passivo NC / Ativo Total atual < anterior)
6. Liquidez Maior (Liquidez Corrente atual > anterior)
7. Sem Diluição de Ações (Qt. Ações atual <= Qt. Ações anterior)

Eficiência Operacional

8. Margem Bruta Maior (Margem Bruta atual > anterior)
9. Giro do Ativo Maior (Giro atual > anterior)

3.4 Seleção Final do Portfólio

Para compor a carteira que segue para a Fase 2, classificamos as empresas do "Universo de Valor" por sua pontuação no F-Score. Selecioneamos os "**Top N**" (ex: 10 ou 15) ativos que obtiveram as **maiores pontuações**. (A definição exata dos limiares de score e do valor de N foi determinada através da otimização de parâmetros no backtest).

Este portfólio final, filtrado por liquidez, valor e qualidade, é então otimizado pela estratégia de Risk Parity na Fase 2.

Fase 2: Otimização e Alocação de Pesos (Risk Parity)

Após a Fase 1 (Filtro de F-score) nos fornecer um universo restrito de empresas com alta pontuação no F-Score, entramos na segunda fase: a alocação de capital.

Simplesmente comprar partes iguais de todas as ações selecionadas (uma alocação $1/N$) ignora uma informação crucial: o risco. Ações com F-Score alto ainda podem ter perfis de risco muito diferentes, como alta volatilidade ou alta correlação entre si.

Para resolver isso, utilizamos uma abordagem quantitativa de alocação de risco conhecida como **Risk Parity (Paridade de Risco)**. O objetivo do modelo Risk Parity é alocar os pesos (w) do portfólio de tal forma que cada ativo contribua igualmente para o risco total da carteira. Isso garante que o risco seja distribuído de forma inteligente entre os ativos de qualidade que selecionamos

O processo é dividido em duas etapas:

Cálculo da Matriz de Covariância

Primeiro, foi necessário estimar o risco de cada ativo e como eles se movem em conjunto.

Coleta de Dados: Obtivemos os retornos diáários históricos (usando a biblioteca `yfinance`) das ações selecionadas na Fase 1, referentes ao período de lookback (ex: 252 dias úteis) anterior à data de rebalanceamento

Matriz de Risco (Σ): Com esses retornos, estimamos a Matriz de Covariância (Σ). Esta matriz é o pilar da alocação, pois contém a variância individual de cada ativo (seu risco próprio) e a covariância entre cada par de ativos (como eles tendem a se mover juntos, ou correlação).

Otimização e Alocação Final de Pesos

O objetivo é encontrar o vetor de pesos (w) que satisfaça a condição de paridade de risco. A contribuição de risco de um único ativo (i) para o portfólio não é apenas sua volatilidade, mas sim seu peso (w_i) multiplicado pela sua "volatilidade marginal de risco" (como o ativo afeta o risco total do portfólio), representada por Σw_i

A fórmula conceitual que buscamos satisfazer é:

$$w_i \cdot (\Sigma w)_i$$

Onde:

- w_i : É o peso do ativo i no portfólio.
- Σw_i : É a volatilidade marginal de risco do ativo i .

No nosso backtest, esta condição ideal não é resolvida algebricamente, mas sim através de um **problema de otimização**. Utilizamos um otimizador (`scipy.optimize.minimize`) para encontrar os pesos w que minimizam a diferença (a soma dos erros quadrados) entre a contribuição de risco de cada ativo e a contribuição de risco média.

O resultado final é um vetor de pesos onde, conceitualmente, ações mais voláteis ou mais correlacionadas com os outros ativos recebem pesos menores, e ações menos voláteis ou descorrelacionadas recebem pesos maiores. Isso garante que, no momento do rebalanceamento, o portfólio esteja balanceado não pelo seu valor financeiro ($1/N$), mas sim pelo seu risco.

4. Regras de Portfólio e Parâmetros do Backtest

Para simular a estratégia do "Robô Quantowksy" ao longo do tempo, definimos um conjunto rigoroso de regras de portfólio.

A decisão central foi a frequência de rebalanceamento. Testes preliminares (cujos resultados não foram incluídos neste relatório) que utilizavam um rebalanceamento de pesos mais frequente (ex: trimestral) mostraram um aumento significativo no *turnover* (giro da carteira). Como apontado por nossa equipe, "Aumentar o tempo entre as Operações, reduziria custo.". Concordamos com essa premissa e, para mitigar o impacto dos custos de transação, adotamos uma política de rebalanceamento **anual** para seleção de ativos e alocação de pesos.

A cada ano, em uma data fixa, o processo de rebalanceamento é refeito do zero, seguindo 5 etapas:

1. **Prevenção de Lookahead Bias:** Fixamos a data de rebalanceamento em 1º de Maio de cada ano (ex: 01/05/2015). Esta data foi escolhida para garantir que, no momento da

seleção, os dados contábeis do ano-sinal (ex: 31/12/2014) já tivessem sido auditados e publicados pela vasta maioria das empresas, evitando o viés de usar informações que não estariam publicamente disponíveis.

2. **Definição do Universo (Ano t):** O "Universo Investível" é definido aplicando o filtro de Liquidez. Calculamos o volume financeiro médio diário (liquidez mínima) dos 12 meses anteriores (ex: 01/05/2014 a 30/04/2015) e selecionamos apenas os ativos que negociaram acima de R\$ 1 milhão/dia.
3. **Seleção de Ativos (Ano t):** Aplicamos o filtro de Qualidade (F-Score) ao universo líquido, usando os dados do `fscore_final_por_empresa.parquet` (baseados no sinal do Ano $t-1$):
 - **Venda:** Ativos atualmente em carteira (`holdings_ano_anterior`) são vendidos se seu novo F-Score for *menor* que o limiar de venda (`f-score_”venda”`).
 - **Manutenção:** Ativos são mantidos se seu F-Score for *maior ou igual* ao `f-score_”venda”`.
 - **Compra:** Os "slots" vagos no portfólio são preenchidos com os melhores ativos do universo que (a) ainda não estão na carteira e (b) possuem um F-Score *maior ou igual* ao `f-score_”compra”`. A seleção é ordenada pelo maior F-Score.
4. **Alocação de Pesos (Ano t):** Para os ativos selecionados aplicamos a **Otimização Risk Parity (ERC)**. Calculamos a matriz de covariância usando os retornos diários dos 252 dias úteis anteriores à data de rebalanceamento e, em seguida, otimizamos os pesos para que cada ativo contribua igualmente para o risco total do portfólio.
5. **Custos e Holding (Ano t até $t+1$):** Calculamos o *turnover* (a porcentagem da carteira que foi negociada) e aplicamos um custo de transação (custo de transação = 0.002) sobre esse giro. A carteira resultante é mantida por 12 meses, até a próxima data de rebalanceamento.

5. Backtest

Após o modelo e as regras de portfólio, foi executado um programa que testa os melhores índices, como número de ativos na carteira, `f-score_compra` e `f-score_venda`.

--- Ranking Final (Ordenado por F-Score)			
N	F_Compra	F_Venda	Retorno
12	6	4	0.18
11	6	4	0.18
10	6	4	0.15
13	5	3	0.14
15	7	5	0.13
10	7	5	0.13
12	7	5	0.13
11	7	5	0.13

Onde é possível ver que embora hajam índices outliers, há um índice em específico (compra f-score = 7, venda f-score = 5) que não muda muito para qualquer N (de número de ativos na carteira), portanto este foi selecionado a fim de testes.

Teste com parâmetros



Número de ações na carteira = 10 / F-Score-Compra = 7 / F-Score-Venda = 5

Liquidez Mínima = 1 M

Custo de Transação = 0.002

Teste com parâmetros

Período Analisado: 2015-05-04 a 2024-04-30 (9.0 anos)		
Métrica	Estratégia	Benchmark
Retorno Total	238.56%	123.95%
Retorno Médio Anual	14.53%	9.38%
Volatilidade Anual	22.53%	24.67%
Sharpe Ratio (Rf=0)	0.64	0.38
Max Drawdown	-46.89%	-46.82%

Número de ações na carteira = 10 / F-Score-Compra = 7 / F-Score-Venda = 5

Liquidez Mínima = 0.5M

Custo de Transação = 0.002

6. Conclusão

Nossa análise de backtest (2015-2024), aplicando rebalanceamento anual e custos de transação realistas (0.002), revelou que a estratégia "Quantowski" bateu o benchmark do Ibovespa em sharp e volatilidade, e com uma expressiva diferença no retorno final, especialmente no teste com liquidez = 0.5M de 238% em 9 anos.

A performance superior do filtro de liquidez mais baixo (R\$ 0.5M vs R\$ 1M) sugere uma importante sinergia entre os fatores. O filtro mais restritivo de R\$ 1M, embora mais seguro para execução, tende a limitar o universo a ações de maior capitalização (large caps). Ao reduzir o filtro para R\$ 0.5M, a estratégia ganhou acesso a um universo de small e mid-caps. O F-Score de Piotroski é classicamente uma ferramenta de value investing, desenhada para encontrar valor em empresas negligenciadas, que são frequentemente as de menor capitalização e liquidez. O filtro de R\$ 1M estava inadvertidamente excluindo os ativos onde a estratégia de F-Score tem seu maior potencial de encontrar alfa.

O modelo ainda não atingiu a maturidade para implementação. O próximo passo crítico é refinar a Fase 1 (Seleção de Ativos), integrando fatores adicionais, como o filtro de Valor (P/VPA) – que se mostrou metodologicamente complexo pela falta de dados históricos de quantidade de ações.

7. Fonte de Dados e USO de IA GENERATIVA

Para o filtro do F-Score, houve a necessidade de um trabalho de engenharia de dados extenso. Começando pela fonte principal, o [Portal de Dados abertos da CVM](#), onde extraímos dados referentes desde 2012 a 2024 para a progressão do modelo.

Nesta fase, foi destacada o maior papel da IA GENERATIVA (Gemini PRO) para o mapeamento dos dados, filtragem e construção de uma fonte nova limpa para o backtest, que prosseguimos com mais detalhes a seguir.

7.1 Engenharia com uso de IA GENERATIVA

A fonte de dados da CVM é granular, com informações anuais distribuídas em múltiplos arquivos (DRE, BPA, BPP, DFC, etc.), cada um com sua própria estrutura.

Para modelar o F-Score, foi necessário um extenso trabalho em conjunto. Utilizando o Gemini, fornecemos resumos das estruturas de conta (como o `modelobasecvm.txt`) e solicitamos o mapeamento dos 9 critérios do F-Score para os arquivos e códigos de referência corretos.

Um exemplo crítico dessa análise foi a filtragem setorial. O Gemini ajudou a identificar que empresas financeiras possuem um plano de contas distinto (ex: Receitas de Intermediação Financeira), que não é compatível com o modelo Piotroski, permitindo-nos criar uma regra para excluí-las e focar em empresas não-financeiras (que reportam Receita de Venda de Bens e/ou Serviços).

O desafio final foi conectar os sinais (indexados por CNPJ) aos dados de mercado (indexados por Ticker). A biblioteca [yfinance](#) não oferece uma função para buscar tickers por CNPJ ou listar composições históricas de índices.

Para resolver isso, extraímos a lista única de CNPJs do nosso universo (Ibovespa) e utilizamos o Gemini para, de forma programática, gerar o mapa de tradução CNPJ -> Ticker (ex: 02.916.265/0001-60 -> JBSS3.SA). Essa base de apoio (`cnpj-ticker.csv`) foi a "ponte" essencial que permitiu ao script de backtest requisitar os dados de preço corretos para cada empresa.

E claro, como funções secundárias, estão a revisão e correção deste relatório, análise de viés de código backtest, vibe coding, brainstorm, geração logo etc. A partir disto, a IA teve um papel fundamental na construção deste projeto, tornando-se algo cultural.

